

[연구제안서] Multimodal Long Video Token Compression

시공간 2축 적응형 토큰 압축 기반 차세대 온디바이스 옴니모달 아키텍처

정현우 (Hyeonwoo Jung)

POSTECH / AI 대학원 지원 연구계획서

hyeonwoo.research@postech.ac.kr

2026년 08월 26일

Abstract

최신 멀티모달 대형 언어 모델(MLLM)은 고해상도 영상 및 오디오 처리 시 트랜스포머 Self-Attention의 이차 복잡도 $O(N^2)$ 로 인해 극심한 연산 및 메모리 절벽에 직면한다. 90분 분량의 비디오는 최대 5,400만(54M) 토큰을 유발하여 온디바이스 실시간 추론을 마비시킨다. 본 연구는 선행 연구인 FastV(깊이 축 토큰 프루닝), StreamKV(시간 축 캐시 관리), OmniSelect(질문 기반 모달리티 게이팅)의 한계를 심층 분석하고, 이들의 모순을 해소하는 시공간 2축 적응형 압축 아키텍처(DA-MLLM)를 제안한다. 제안 기법은 FLOPs 65% 절감, KV Cache 메모리 80% 감축, 초당 프레임 3.2배 향상을 달성하면서도 Video-MME 등 핵심 벤치마크 성능을 98.5% 이상 방어하는 것을 목표로 한다.

1 연구 배경 및 극한 병목 (Problem)

트랜스포머의 Self-Attention 메커니즘은 시퀀스 길이 N 에 대해 $O(N^2)$ 연산 복잡도와 $O(N)$ KV Cache 메모리 풋프린트를 요구한다.

- 토큰 팽창 수치: 텍스트 프롬프트가 수백 토큰인 반면, 90분 영상은 약 5,400만(54M) 토큰을 생성.
- 온디바이스 한계: 스마트 글래스 및 로봇 엣지 칩셋(Jetson, NPU)의 한정된 SRAM 및 대역폭에서 실시간 서빙 불가능.

2 선행 연구 맹점 비판 (Prior Art Critique)

기존 연구들은 특정 모달리티나 단일 축에 치우쳐 상호 충돌을 겪는다:

- FastV (ECCV 2024):** Layer 2 이후 하위 50% 토큰 드롭으로 FLOPs 45% 절감했으나, 정적 이미지에 국한되어 비디오 시간축 인과관계(Temporal Causality) 왜곡 및 정적 고정 비율 컷으로 미세 정보 소실 발생.
- StreamKV:** 슬라이딩 윈도우로 KV Cache는 줄이나 토큰 텐서 자체의 FFN 연산은 감축 불가.
- OmniSelect (2026):** 질문에 따라 모달리티 프루닝 비율을 동적 조절하나, 트랜스포머 내부 레이어 깊이별 정보 집약(Anchor Sink) 특성을 반영하지 못함.

3 핵심 제안 기법 (Proposed Method)

본 제안서는 **Dual-Axis Adaptive MLLM (DA-MLLM)**을 통해 깊이 축과 시간 축을 동시 압축한다.

3.1 수학적 수식화

1. 질문 반응형 모달리티 가중치 산출:

$$\alpha_v, \alpha_a = \text{Softmax}(\mathbf{W}_g \cdot [\text{Embed}(Q); \text{Pooling}(V); \text{Pooling}(A)]) \quad (1)$$

2. 레이어 축 깊이별 적응형 프루닝: 질문 복잡도 $C(Q)$ 에 따라 프루닝 시작 레이어 K^* 와 제거율 R^* 를 동적 결정:

$$K^* = \lfloor K_0 + \beta \cdot C(Q) \rfloor, \quad R^* = R_0 \cdot (1 - \alpha_v) \quad (2)$$

Layer K^* 통과 후 평균 어텐션 점수 $\phi_{\text{attn}}(t)$ 하위 R^* 토큰을 FFN 통과 직전 텐서에서 영구 제거.

3. 시간축 캐시 슬라이딩 정렬: 가변 토큰 프루닝 시 발생하는 PagedAttention 메모리 인덱싱 충돌을 해결하기 위해, **Time-Anchor Indexing Mask**를 설계하여 공간 토큰은 삭제하되 각 타임스탬프의 기준 앵커 토큰만 KV 캐시에 압축 유지.

4 정량적 목표 및 실험 검증

- 연산량(FLOPs): 베이스라인 대비 **65% 이상 절감**.
- 메모리 풋프린트: 1시간 비디오 스트리밍 시 KV Cache **80% 이상 감축**.
- 추론 속도: Jetson Orin 엣지 기준 **3.2배 향상** (15 FPS $\rightarrow$ 48 FPS 실시간성 확보).
- 정확도 보존: Video-MME, MMMU 벤치마크 **98.5% 이상 유지**.

5 킬러 활용처: 온디바이스 라이프로그

사용자의 시야와 음성을 24시간 실시간 캡처하는 스마트 글래스(AI Life-Companion) 환경에서, 배터리 방전과 발열 없이 초장시간 비디오 인과 추론 완벽 구현.