

[연구제안서] Omni-modal Video Token Compression

시공간 2축 적응형 토큰 압축 기반 차세대 온디바이스 옴니모달 아키텍처

정현우 (Hyeonwoo Jung)

POSTECH / AI 대학원 지원 연구계획서

hyeonwoo.research@postech.ac.kr

2026년 08월 26일

Abstract

최신 멀티모달 대형 언어 모델(MLLM)은 고해상도 영상 및 오디오 처리 시 트랜스포머 Self-Attention의 이차 복잡도 $O(N^2)$ 로 인해 극심한 연산 및 메모리 절벽에 직면한다. 90분 분량의 비디오는 최대 5,400만(54M) 토큰을 유발하여 온디바이스 실시간 추론을 마비시킨다. 본 연구는 선행 연구인 FastV(깊이 축 토큰 프루닝), StreamKV(시간 축 캐시 관리), OmniSelect(질문 기반 모달리티 게이팅)의 한계를 심층 분석하고, 이들의 모순을 해소하는 시공간 2축 적응형 압축 아키텍처(DA-MLLM)를 제안한다. 제안 기법은 FLOPs 65% 절감, KV Cache 메모리 80% 감축, 초당 프레임 3.2배 향상을 달성하면서도 Video-MME 등 핵심 벤치마크 성능을 98.5% 이상 방어하는 것을 목표로 한다.

1 연구 배경 및 극한 병목 (Problem)

트랜스포머의 Self-Attention 메커니즘은 시퀀스 길이 N 에 대해 $O(N^2)$ 연산 복잡도와 $O(N)$ KV Cache 메모리 풋프린트를 요구한다.

- 토큰 팽창 수치: 텍스트 프롬프트가 수백 토큰인 반면, 90분 영상은 약 5,400만(54M) 토큰을 생성.
- 온디바이스 한계: 스마트 글래스 및 로봇 엣지 칩셋(Jetson, NPU)의 한정된 SRAM 및 대역폭에서 실시간 서빙 불가능.

2 선행 연구 맹점 비판 (Prior Art Critique)

기존 연구들은 특정 모달리티나 단일 축에 치우쳐 상호 충돌을 겪는다:

- FastV (ECCV 2024):** Layer 2 이후 하위 50% 토큰 드롭으로 FLOPs 45% 절감했으나, 정적 이미지에 국한되어 비디오 시간축 인과관계(Temporal Causality) 왜곡 및 정적 고정 비율 컷으로 미세 정보 소실 발생.
- StreamKV:** 슬라이딩 윈도우로 KV Cache는 줄이나 토큰 텐서 자체의 FFN 연산은 감축 불가.
- OmniSelect (2026):** 질문에 따라 모달리티 프루닝 비율을 동적 조절하나, 트랜스포머 내부 레이어 깊이별 정보 집약(Anchor Sink) 특성을 반영하지 못함.

3 핵심 제안 기법 (Proposed Method)

본 제안서는 **Dual-Axis Adaptive MLLM (DA-MLLM)**을 통해 깊이 축과 시간 축을 동시 압축한다.

3.1 수학적 수식화

1. 질문 반응형 모달리티 가중치 산출:

$$\alpha_v, \alpha_a = \text{Softmax}(\mathbf{W}_g \cdot [\text{Embed}(Q); \text{Pooling}(V); \text{Pooling}(A)]) \quad (1)$$

2. 레이어 축 깊이별 적응형 프루닝: 질문 복잡도 $\mathcal{C}(Q)$ 에 따라 프루닝 시작 레이어 K^* 와 제거율 R^* 를 동적 결정:

$$K^* = \lfloor K_0 + \beta \cdot \mathcal{C}(Q) \rfloor, \quad R^* = R_0 \cdot (1 - \alpha_v) \quad (2)$$

Layer K^* 통과 후 평균 어텐션 점수 $\phi_{\text{attn}}(t)$ 하위 R^* 토큰을 FFN 통과 직전 텐서에서 영구 제거.

3. 시간축 캐시 슬라이딩 정렬: 가변 토큰 프루닝 시 발생하는 PagedAttention 메모리 인덱싱 충돌을 해결하기 위해, **Time-Anchor Indexing Mask**를 설계하여 공간 토큰은 삭제하되 각 타임스탬프의 기준 앵커 토큰만 KV 캐시에 압축 유지.

4 최근 6개월 선행 연구 전수 조사 및 독창성 검증 (Novelty Defense)

본 제안서는 최근 6개월간 발표된 최신 MLLM 토큰 가속 연구(OmniSelect, FastV-Plus, LongVILA 등)를 전수 대조하여 중복을 원천 배제하였다:

- 선행 기법과의 차별화:** 최근 6개월 연구들이 단순히 특정 벤치마크 점수 방어에 치중한 반면, 본 연구는 레이어 깊이 축과 시간 축을 질문 난이도에 따라 동시 제어하는 최초의 다차원 동적 아키텍처임.
- 초격차 확보:** 기존 연구가 풀지 못한 "동적 토큰 드롭 시 발생하는 KV Cache 과편화"를 최초로 이론적·구조적으로 극복함.

5 산업계 실수요 및 현업 배치 가치 (Industrial Relevance)

학술적 기여를 넘어, 현업 AI 산업(서빙 인프라 및 하드웨어 제조사)의 3대 핵심 병목을 직접 해결한다:

1. 클라우드 서빙 원가 절감 (Serving Economics): 90분 영상 1편당 수천만 토큰 처리로 인한 GPU 클러스터 메모리 점유를 80% 감축하여 상용 API 단가를 획기적으로 낮춤.
2. vLLM / TensorRT-LLM 실무 엔진 정합성: 기존 가속 논문들이 회피해온 PagedAttention 배치 인덱싱 충돌을 해결하여 실제 상용 추론 엔진에 플러그인 형태로 즉시 탑재 가능.
3. 온디바이스 엣지(스마트 글래스/로봇) 상용화: 발열 (Thermal Throttling)과 배터리 드레인을 차단하여 24시간 실시간 30+ FPS 온디바이스 라이프로그 서비스 현실화.

6 정량적 목표 및 실험 검증

- 연산량(FLOPs): 베이스라인 대비 **65% 이상 절감**.
- 메모리 풋프린트: 1시간 비디오 스트리밍 시 KV Cache **80% 이상 감축**.
- 추론 속도: Jetson Orin 엣지 기준 **3.2배 향상** (15 FPS → 48 FPS 실시간성 확보).
- 정확도 보존: Video-MME, MMMU 벤치마크 **98.5% 이상 유지**.