

[사내 기술 제안서 및 종합 서베이] HyperCLOVA X Omni 8B 서빙 가속을 위한 PagedAttention 정합형 시공간 2축 적응형 토큰 압축 아키텍처

A Comprehensive Survey on Multimodal Token Compression and Block-Aligned Serving
Acceleration for NAVER HyperCLOVA X Omni

정현우 (Hyeonwoo Jung)

네이버클라우드 HyperCLOVA X Omni 팀 연구 인턴 (NAVER Cloud Research Intern)

hyeonwoo.jung@navercorp.com

2026년 08월 26일

Abstract

네이버클라우드의 파운데이션 모델인 HyperCLOVA X SEED Omni 8B (HCX Omni)는 시각·음향·텍스트의 Any-to-Any 융합을 이뤄냈으나, 실시간 스트리밍 비디오 및 오디오 처리 시 트랜스포머의 $O(N^2)$ Self-Attention 복잡도와 32K 고정 컨텍스트 제약으로 인해 엔터프라이즈 서빙 단가 폭증 및 대화 턴테이킹 지연 (Turn-taking Latency > 1.2s)이라는 상용화 병목에 직면해 있다. 특히 기존 학술 논문들은 단일 배치 ($B=1$) 환경에만 간혀 있어, 실제 네이버 서빙 인프라인 vLLM/TensorRT-LLM의 PagedAttention 환경에서 심각한 메모리 단편화 (Fragmentation)를 유발한다. 본 제안서는 멀티모달 토큰 압축, 비디오 장기 추론, 스트리밍 KV Cache 관리, 서빙 인프라에 걸친 **선행 연구 24편을 전수 조사한 서베이**를 바탕으로, HCX Omni 8B의 4대 핵심 결함을 진단하고, vLLM 블록 할당자와 수학적으로 정합되는 **Time-Anchor Block-Aligned 2-Axis Compression (TABA)** 아키텍처를 제안한다. 이를 통해 사내 서빙 처리량 (Throughput) 4.2배 증대, GPU VRAM 점유 80% 감축, 턴테이킹 180ms 미만 단축을 달성하여 네이버 옴니 서비스 상용화를 직접 견인하고자 한다.

1 서론 및 HCX Omni 8B의 4대 병목 분석

네이버클라우드의 HCX SEED Omni 8B(2024)는 8단계 점진적 사전학습 (Text:Image:Audio = 20:65:15)을 통해 한국어 멀티모달 최고 성능을 확보했으나, 실제 상용 서비스 배포 시 다음 4가지 치명적 엔지니어링 한계를 노출한다.

1.1 비디오·오디오 토큰 폭증과 KV Cache 폭발

HCX Omni는 MambaMia 음성 인코더 (1Hz 압축)를 연동하지만, 15분 이상의 실시간 라이브 영상만 유입되어도 수백만 개의 토큰이 누적된다. 트랜스포머의 Self-Attention은 시퀀스 길이 N 에 대해 $O(N^2)$ 연산량과 선형 $O(N)$ KV Cache 메모리를 요구하므로, 32K 컨텍스트를 초과하는 순간 GPU OOM이 발생하거나 선두 프레임을 강제 절단하는 정보 소실이 강제된다.

1.2 Video-MME 실증 데이터로 본 1D RoPE의 결함

공인 장기 비디오 벤치마크인 Video-MME (CVPR 2024) 및 MLVU에서, 1D RoPE 기반 모델군 (LLaVA-Video, HCX Omni)은 공간적 객체 인식 (Spatial Perception, 68.4%) 대비, '시간적 인과 추론 (Temporal Reasoning)' 및 15분 이상 장기 영상 태스크에서 41.2%로 무려 27.2%p 폭락하는 치명적 취약점을 노출한다. 1D RoPE가 프레임당 토큰 수 $P(=576)$ 만큼 시간 축 인덱스를 $\text{pos}(t+1) = \text{pos}(t) + P$ 로 왜곡 팽창시켜 회전 임베딩의 고주파 대역이 시간 축에서 급격한 앨리어싱 (Aliasing)을 겪기 때문이다. 실제로 Qwen2-VL은 이를 (t, h, w) 3D로 분해하는 M-RoPE를 통해 해당 벤치마크 점수를 +14.2%p 즉각 반등시킴으로써 1D RoPE의 한계를 실증했다.

1.3 모달리티 간 토큰 경쟁 및 턴테이킹 지연

영상 입력 토큰 수가 전체 시퀀스의 70% 이상을 독점하면서, 정작 사용자의 핵심 질문이 담긴 음성 (Audio) 토큰에 어텐션이 충분히 분배되지 못한다. 또한 순차적 Autoregressive 생성 파이프라인으로 인해 음성 질문 입력 후 답변 생성까지 1.2~2.0초의 침묵 지연이 발생하여 자연스러운 인터랙트 (Barge-in)가 불가능하다.

1.4 산업 현장 vLLM 서빙 메모리 과편화

엔터프라이즈 환경에서 네이버클라우드는 단일 인스턴스가 아닌 vLLM Continuous Batching 기반으로 다중 요청을 묶어 서빙한다. 그러나 기존의 동적 토큰 프루닝 알고리즘을 적용하면 요청마다 토큰 길이가 제각각으로 줄어들어, vLLM의 16/32-토큰 고정 블록 기반 PagedAttention 메모리 풀이 산산조각 나며 실제 서빙 Throughput이 역전된다.

2 멀티모달 토큰 압축 5대 기술 서베이

본 제안서는 최신 6개월 (2026년) 논문 및 분야별 핵심 연구 24편을 5대 축으로 체계화하여 분석하였다.

2.1 공간 축 이미지 토큰 압축 (Spatial Reduction)

- **ToMe (ICLR 2023)**: 이분 매칭 (Bipartite Matching) 을 통해 유사한 이미지 토큰을 순차 병합하여 $O(N)$ 연산 감축.
- **FastV (ECCV 2024)**: 깊은 레이어로 갈수록 이미지 어텐션이 0.21%로 급락하는 현상을 포착, Layer 2 이후 하위 50%를 드롭하여 FLOPs 45% 절감.
- **VisionZip / PruMerge (2024)**: 시각 CLS 토큰과의 코사인 유사도 기반 동적 선택 및 클러스터링.
- **When Vision Becomes Text (2026)**: 레이어가 깊어지며 시각 정보가 텍스트 토큰으로 전이되는 잔차 (Cross-Modal Residual) 를 추적하여 흡수된 시각 토큰 선별 제거.

2.2 시공간 비디오 토큰 압축 (Spatiotemporal Video)

- **HieraVid (2026.02)**: 비디오를 세그먼트 (Segment) → 프레임 (Frame) → 트랜스포머 레이어 (Layer) 의 3단계 계층 구조로 점진적 압축.
- **VisionTrim / ForestPrune (2026.04)**: 시공간 토큰 연속성을 포레스트 (Forest) 트리 그래프로 모델링하여 90% 압축 달성.
- **EvoPrune (2026.04)**: LLM 이전 ViT 인코더 단계에서 조기 프루닝을 수행하여 전처리 연산 절감.
- **LongVILA (2024)**: 초장거리 비디오 모델을 위한 시스템-알고리즘 통합 설계.

2.3 옴니모달 경합 및 동적 게이팅 (Cross-Modal)

- **OmniSelect (2026.05)**: AudioCLIP을 도입하여 질문 의미에 따라 오디오 vs 비디오 프루닝 비율을 동적 배분함으로써 모달리티 간 토큰 경쟁 최소화 해결.
- **Moshi (Kyutai 2024)**: Mimi 코덱 (12.5Hz) 과 Dual-Stream Inner Monologue를 결합해 160ms 지연의 Full-Duplex 대화 실현.
- **Mini-Omni2 (2024)**: 실시간 인터럽트 및 적응형 상태 머신을 적용한 옴니 에이전트.

2.4 스트리밍 KV Cache 관리 (KV Cache Eviction)

- **StreamKV (2024)**: 슬라이딩 윈도우와 대표 키토큰만 선별 보존하여 스트리밍 메모리 억제.
- **SnapKV / PyramidKV (2024)**: 관찰 윈도우의 어텐션 분포에 기반하여 레이어별로 차등적 KV Cache 용량 할당.
- **StreamingLLM / H2O (NeurIPS 2023)**: 초기 Attention Sink 토큰과 최근 토큰만 보존하여 무한 길이 생성 지원.

2.5 상용 서빙 인프라 아키텍처 (Serving Systems)

- **vLLM (SOSP 2023)**: PagedAttention을 도입하여 KV Cache를 16/32 크기의 고정 블록 단위 가상 메모리로 관리, 메모리 낭비 제거.
- **Sarathi-Serve (OSDI 2024)**: Chunked-Prefill을 통해 거대 프롬프트 연산과 실시간 디코딩을 시분할 다중화.
- **OOD-VTP (2026)**: 언어 임베딩 분포와 동떨어진 OOD 시각 토큰을 처냄으로써 환각 (Hallucination) 및 보안 탈옥을 방어.

3 선행 연구 24편 비교 분석 매트릭스

표 1은 조사된 선행 연구 24편을 8대 기준으로 전수 비교한 종합 매트릭스이다.

4 기술적 돌파구: TABA 아키텍처 상세 설계

4.1 선행 연구의 공통 결함 (The vLLM Serving Dilemma)

표 1가 명백히 보여주듯, 기존 24개 연구 중 "토큰을 처내면서 동시에 상용 vLLM PagedAttention 블록 (16 토큰) 과 정합되는 연구는 전무"하다. 단일 배치 ($B=1$) 벤치마크에서는 토큰을 임의로 날려도 빨라 보이지만, 네이비클라우드의 Continuous Batching 환경에서는 각 요청의 길이가 불규칙해져 블록 할당자가 깨지고 패딩 오버헤드가 발생한다.

4.2 TABA (Time-Anchor Block-Aligned) 수학적 수식화

본 연구는 토큰 단위가 아닌 16개 토큰 단위의 PagedAttention 블록 단위 마스킹을 수행한다.

1. 질문 기반 모달리티 중요도 산출:

$$\alpha_v, \alpha_a = \text{Softmax}(\mathbf{W}_g \cdot [\text{Embed}(Q); \text{Pool}(V); \text{Pool}(A)]) \quad (1)$$

2. 블록 단위 타임-앵커 스코어링: 비디오 토큰을 vLLM의 물리 블록 크기 $B_s (= 16)$ 에 맞춰 블록 $\mathcal{B}_i = \{v_{(i-1)B_s+1}, \dots, v_{iB_s}\}$ 로 분할한다. 블록 내 평균 어텐션과 시간축 앵커 보존도를 결합한 블록 점수 $S(\mathcal{B}_i)$ 를 산출:

$$S(\mathcal{B}_i) = \frac{1}{B_s} \sum_{v \in \mathcal{B}_i} \phi_{\text{attn}}(v) + \gamma \cdot \text{AnchorScore}(t_i) \quad (2)$$

3. 블록 할당자 직접 회수 (Zero-Fragmentation Eviction):

$$\mathcal{M}(\mathcal{B}_i) = \mathbb{I}(S(\mathcal{B}_i) \geq \tau \cdot (1 - \alpha_v)) \quad (3)$$

$\mathcal{M}(\mathcal{B}_i) = 0$ 인 블록은 토큰을 개별 삭제하는 것이 아니라, vLLM의 `block_allocator.free()` 를 직접 호출하여 물리 메모리 블록을 즉각 회수한다. 이를 통해 배치 내 다른 요청이 해당 블록을 즉시 재사용할 수 있다.

Table 1: 멀티모달 토큰 압축 및 가속 선행 연구 24편 종합 비교 매트릭스 (Survey Matrix)

분야	논문 / 모델	발표 시점	타겟 모달리티	압축 메커니즘	프루닝 단위	무 학습	vLLM 정합	결정적 맹점 (Frontier Blind Spot)
Spatial	ToMe	ICLR 2023	Image	Similarity Merging	Token-level	O	X	비디오 시간축 인과성 반영 불가
	FastV	ECCV 2024	Image	Attention Pruning	Token-level	O	X	정적 $K=2, R=50\%$ 고정 of 경직성, 비디오 왜곡
	LLaVA-PruMerge	arXiv 2024	Image	Adaptive Merging	Cluster-level	O	X	복잡한 클러스터링으로 인한 인퍼런스 오버헤드
	VisionZip	arXiv 2024	Image	Feature Correlation	Token-level	O	X	텍스트 질문 의도 미반영
	SparseVLM	arXiv 2024	Image	Text-guided Pruning	Token-level	O	X	영상-음성 동시 입력 처리 불가
	When Vision Becomes Text	arXiv 2026.03	Image	Cross-Modal Residual	Token-level	O	X	가변 길이로 인한 PagedAttention 블록 파편화
Video	Video-LLaVA	arXiv 2023	Video	Naive Frame Sample	Frame-level	X	O	2,048 고정 토큰으로 장기 영상 인과성 관계
	LongVILA	arXiv 2024	Video	System-Algorithm	Frame-level	X	O	대규모 분산 GPU 필수, 단일 노드 서빙 비효율
	HieraVid	arXiv 2026.02	Video	Hierarchical 3-Stage	Segment/Frame/Layer Node/Token	O	X	3단계 동적 길이로 vLLM 배치 처리량 급락
	ForestPrune	arXiv 2026.03	Video	Spatiotemporal Graph	Node/Token	O	X	비디오 그래프 구성 오버헤드로 실시간 성 저하
	VisionTrim	arXiv 2026.04	Video	Dominant Selection	Token-level	O	X	오디오 스트림과의 동시 어텐션 경쟁 미해결
	EvoPrune	arXiv 2026.04	Video	Early ViT Pruning	Patch-level	O	X	백본 LLM 내부 어텐션 낭비는 미해결
Omni	HCX SEED	NAVER 2024	Any-to-Any	8-Stage Foundation	Full-sequence	X	O	1D RoPE 왜곡, 32K 벽, 토크이징 지연(> 1.2s)
	Omni 8B OmniSelect	arXiv 2026.05	Audio+Video	Modality-Aware Gating	Sequence-level	O	X	트랜스포머 깊이별 정보 집약(Anchor Sink) 미활용
	Moshi	Kyutai 2024	Speech	Dual-Stream Mimi	Codebook-level	X	X	영상 모달리티 이해 기능 부재
	Mini-Omni2	arXiv 2024	Audio+Video	Cross-modal SFT	Token-level	X	X	실시간 서빙 엔지니어링 메모리 최적화 부재
	Emu3	BAAI 2024	Any-to-Any	Next-Token AR	Discrete Token	X	O	이산 토큰 양자화 손실 및 막대한 연산량
KV Cache	StreamingLLM	ICLR 2024	Text	Attention Sink	Token-level	O	O	텍스트 전용, 멀티모달 시각 토큰 중복 반영 불가
	H2O	NeurIPS 2023	Text	Heavy Greedy	Token-level	O	X	그리디 드롭으로 인한 PagedAttention 블록 충돌
	SnapKV	arXiv 2024	Text	Window Pooling	Head-level	O	X	비디오의 프레임 간 시간적 상관관계 무시
	PyramidKV	arXiv 2024	Text	Layer-wise Pyramid	Layer-level	O	X	정적 레이어 피라미드로 멀티모달 가변성 취약
	StreamKV	arXiv 2024	Video	Window Eviction	Chunk-level	O	X	FFN 연산은 줄이지 못하고 캐시 크기만 제한
Serving	vLLM (PagedAttention)	SOSP 2023	Systems	Virtual Memory	16/32 Block	N/A	O	동적 토큰 삭제 시 내부 단편화 및 패딩 유발
	OOD-VTP	arXiv 2026.02	Safety	Out-of-Distribution	Token-level	O	X	안전성은 높이나 서빙 속도 개선 폭 미미
본 제안	TABA (Proposed)	2026 (사내 제안)	Audio+Video	Time-Anchor 2-Axis	16-Token Block	O	O	vLLM PagedAttention 블록과 완벽 정합 (최초)

5 네이버 현업 배치 청사진 및 정량 목표

5.1 네이버클라우드 서빙 파이프라인 연동

네이버 사내 GPU 클러스터(A100/H100) 상에 배포된 HCX Omni 서빙 컨테이너의 vLLM 커널을 패치하여, Prefill 직후 TABA 블록 마스크 커널을 구동한다.

5.2 정량적 목표 지표

- 서빙 **Throughput**: A100(80GB) 8-GPU 노드 기준 4.2배 증대 (동시 처리 요청 수 폭증).
- **KV Cache 메모리**: 30분 비디오 처리 시 80% 감축 (32K 컨텍스트 한계 돌파).
- **턴테이킹 지연**: 발화 종료 후 응답 시작까지 180ms 달성 (실시간 풀-듀플렉스 대화).
- **벤치마크 방어율**: Video-MME, Audio-VQA, Ko-MMMU에서 풀 토큰 대비 98.5% 이상 방어.

5.3 네이버 비즈니스 가치

1. 연간 수십억 원 클라우드 인프라 비용 절감: 멀티모달 API 단위 토큰 서빙 원가 혁신.
2. 네이버 서비스 전면 탑재: 네이버 웨일 브라우저, CLOVA X 모바일 앱, 차량용 IVI 시스템에 초경량 실시간 옴니 어시스턴트로 탑재.

6 인턴십 수행 로드맵 및 산출물 (Roadmap)

6.1 3단계 엔지니어링 마일스톤

- 1~2개월차 (vLLM 블록 커널 구현): vLLM의 PagedAttention v2/v3 C++/CUDA 소스를 분석하고, 16-토큰 블록 단위로 메모리를 즉각 동적 반환하는 `block_allocator.free()` 커스텀 커널 프로토타입 완성.
- 3~4개월차 (오프라인 모델 통합 및 평가): HCX Omni 8B 백본에 M-RoPE 3D 시간축 분해 및 TABA 모달리티

터 게이팅을 결합. Video-MME, MLVU, Audio-VQA 벤치마크에서 정확도 98.5% 방어율 및 FLOPs 65% 절감 검증.

- 5~6개월차 (온라인 A/B 테스트 및 사내 배포): 네이버 사내 클러스터 모의 트래픽을 대상으로 Continuous Batching 서버 Throughput 4.2배 향상 실증. 핵심 기술 사내 특허 2건 출원 및 최우수 AI 학회 (NeurIPS/CVPR Systems Track) 공동 논문 제출.

6.2 예상 리스크 및 엔지니어링 안전장치 (Risk Mitigation)

- 리스크 1: 극초반 찰나의 시각 디테일 소실: 사용자가 초 단위 핀포인트 질문을 던질 경우, 시간 앵커 스코어가 낮은 블록이 삭제되어 정보가 유실될 위험. → 대응: 질문 텍스트에서 시간 관련 토큰 (Timestamp) 이 감지되면 해당 앵커 윈도우의 블록 삭제를 일시 동결 (Lock) 하는 안전 규칙 (Rule-based Fallback) 적용.
- 리스크 2: 블록 마스킹 커널의 연산 오버헤드: 블록 스코어를 계산하는 루틴이 오히려 서버 지연을 가중시킬 위험. → 대응: OpenAI Triton 기반 Fused Attention 커널 내부에 블록 리덕션 (Reduction) 을 인라인으로 융합하여 커널 추가 지연을 0.3ms 미만으로 억제.

참고 문헌

1. Bolya et al., "Token Merging: Your ViT But Faster," *ICLR*, 2023.
2. Chen et al., "FastV: An Image is Worth 1/2 Tokens After Layer 2," *ECCV*, 2024.
3. Shang et al., "LLaVA-PruMerge: Adaptive Token Reduction for MLLMs," *arXiv*, 2024.
4. Zhang et al., "VisionZip: Longer is Not Always Better in MLLMs," *arXiv*, 2024.
5. Huang et al., "SparseVLM: Visual Token Sparsification," *arXiv*, 2024.
6. Anonymous et al., "When Vision Becomes Text: Token Pruning with Cross-Modal Residuals," *arXiv*, 2026.
7. Lin et al., "Video-LLaVA: Learning United Visual Representations," *arXiv*, 2023.
8. Ding et al., "LongVILA: Scaling Long-Context Video LLMs," *arXiv*, 2024.
9. Anonymous et al., "HieraVid: Hierarchical Video Token Pruning," *arXiv*, 2026.
10. Anonymous et al., "ForestPrune: Spatiotemporal Forest Modeling for MLLMs," *arXiv*, 2026.
11. Anonymous et al., "VisionTrim: Dominant Vision Token Selection," *arXiv*, 2026.
12. Anonymous et al., "EvoPrune: Early-stage Visual Token Pruning," *arXiv*, 2026.
13. NAVER Cloud, "HyperCLOVA X SEED Omni Technical Report," *NAVER Tech Report*, 2024.
14. Yang et al., "OmniSelect: Dynamic Modality-Aware Token Compression," *arXiv:2605.18041*, 2026.
15. Défossez et al., "Moshi: a speech-text foundation model for real-time dialogue," *Kyutai*, 2024.
16. Xie et al., "Mini-Omni2: Towards Open-source Omni-modal Conversational Agents," *arXiv*, 2024.
17. Wang et al., "Emu3: Next-Token Prediction is All You Need," *BAAI*, 2024.
18. Xiao et al., "Efficient Streaming Language Models with Attention Sinks," *ICLR*, 2024.
19. Zhang et al., "H2O: Heavy-Hitter Oracle for Efficient LLM Serving," *NeurIPS*, 2023.
20. Li et al., "SnapKV: LLM KV Cache Compression on Demand," *arXiv*, 2024.
21. Zhang et al., "PyramidKV: Dynamic Layer-wise KV Cache Allocation," *arXiv*, 2024.
22. Anonymous et al., "StreamKV: Continuous Streaming Video KV Cache," *arXiv*, 2024.
23. Kwon et al., "Efficient Memory Management for Large Language Model Serving with PagedAttention," *SOSP*, 2023.
24. Anonymous et al., "OOD-VTP: Visual Token Pruning for Robustness and Safety," *arXiv*, 2026.